

기술통계: 자료 정리/요약, 특징 파악

- 모집단 규정/표본 추출의 방법에 대한 연구
- 자료 수집방법에 대한 연구
- 수집된 자료를 그래프나 숫자 정보로 요약/유형화
- ex) 인구주택총조사
- 그래프기법, 수치기법
- 평균, 중앙값: 데이터의 중심위치를 나타내기 위해 사용되는 척도
- 범위, 분산, 표준편차: 데이터의 변동성을 나타내기 위해 사용되는 척도

추론통계: 표본 -> 모집단 특성 추측

- 표본으로부터 얻은 정보(통계량)를 이용하여 모집단의 특성(모수)을 추정/예측 또는 일반화
- ex) 대학생들의 한달 평균 음주량은?

도수분포표

계급(구간), 도수(관측값의 개수)

계급값: 각 계급의 중앙값

집중화 경향 - 평균

산술평균(일반적인 데이터 분석, 대부분의 상황)

- 모든 관측값을 반영
- 가장 널리 사용됨
- 이상치에 민감하게 반응

기하평균(성장률, 수익률 등 비율데이터)

- 증감의 평균 변화값 계산시 사용
- $(x_1 \cdot x_2 \cdot x_3 \cdots x_n)^{\frac{1}{n}}$
- 산술평균보다 항상 작거나 같은 값을 가짐

조화평균(속도, 비율의 평균 계산)

- 평균적인 변화율 측정을 위해 사용
 - 사용이 제한적이거나 특정 상황에서 유용 (평균속도 등)
 - $n \cdot (\frac{1}{x_1} + \frac{1}{x_2} + \cdots + \frac{1}{x_n})^{-1}$
-

집중화 경향 - 중앙값

중앙에 위치하는 값
이상치에 영향을 덜받음
소득, 주택가격 등 한쪽으로 치우친 분포에서 유용
홀수 = $(n+1)/2$
짝수 = $n/2, (n+2)/2$ 의 평균

해석

중앙값이 평균보다 작으면 오른쪽으로 치우친 분포
중앙값이 평균보다 크면 왼쪽으로 치우친 분포
중앙값이 평균과 비슷하면 대칭적인 분포

집중화 경향 - 최빈값

관측횟수가 가장 잦은 값
이상치(outlier)에 영향을 덜받음
주로 명목데이터의 경우에 사용
여러개가 존재 할 수 있음
중앙값보다 활용 빈도 낮음
분포 형태파악에 용이

분포형태에 따른 집중화 경향 척도간의 관계

왜도의 이해

분포의 비대칭정도를 나타냄
대칭일수록 값은 영에 근접
피어슨 왜도계수 $3 \times \frac{\text{mean} - \text{median}}{\text{stderr}}$ or $3 \times \frac{\text{mean} - \text{mode}}{\text{stderr}}$

■ 평균과 중앙값 차이가 클수록 비대칭성이 강함

대칭분포에서의 관계
평균, 중앙값, 최빈값 모두 동일
정규분포
이상적인 분포형태

오른쪽 긴 꼬리 분포(우측/양의 왜도)
최빈값 < 중앙값 < 평균

소득분포와 같이 오른쪽으로 치우친분포
극단값이 오른쪽에 존재

왼쪽 긴 꼬리분포(좌측/음의 왜도도)
평균 < 중앙값 < 최빈값
왼쪽으로 치우침
극단값이 왼쪽에 존재
수명

중심위치 척도의 선택

고려할 사항들: 자료특성/분포형태, 극단값 존재여부, 통계분석의 목적

평균: 데이터가 대칭적으로 분포, 극단값이 없거나 적음, 추가적인 통계분석이 필요한 경우
중앙값: 극단값이 존재, 소득/자산 등 경제 데이터, 분포가 치우친 경우
최빈값: 명목척도 데이터, 가장대초적인 범주를 찾을 때

산포경향의 측정

범위(Range)

가장 단순한 산포측정방법
최대값 - 최소값
극단값에 민감
모든관측값을 고려하지않음

표준편차(Std Deviation)

평균으로부터 관측값들의 평균적인 거리
 $\sqrt{\text{분산}}$
원래 측정단위와 동일한 단위 사용
데이터의 변동성을 효과적으로 측정

분산(Variation)

관측값들이 평균으로부터 떨어진거리의 제곱평균
모집단분산과 표본분산으로 구분
극단값에 민감
통계적추론의 기초

상대위치 척도

상대위치 척도의 중요성
개별관측값의 상대적위치 파악

이상치 탐지에 유용
비모수적 통계분석의 기초
분포형태에 영향을 받지않음

백분위수(Percentile)

데이터를 100 등분하는 위치값

p번째 백분위수는 전체관측값 중 p%가 그 값보다 작거나 같음

중앙값은 50번째 백분위수

사분위수(Quartiles)

데이터를 4등분하는 위치값

Q1(25%) Q2(50%) Q3(75%)

중앙값 = Q2

사분위 범위(사분위 편차): Q3-Q1

분산의 이해

관측값들이 평균으로부터 떨어진거리의 제곱평균

각 관측치의 평균의 차이(편차)를 제곱하여 합한 후 모수 n으로 나눔

모든 관측치를 고려하여 변동성을 측정

편차의 제곱을 사용하므로 항상 0이상

모집단 분산: $\sigma^2 = \frac{1}{n} \sum (x - \mu)^2$

표본분산: $S^2 = \frac{1}{n-1} \sum (x - \bar{X})^2$

표준편차의 이해

분산의 제곱근

모집단: $\sigma = \sqrt{var_p}$

표본: $S = \sqrt{var_s}$

해석

관측값들이 평균으로부터 얼마나 떨어져있는지를 원래단위로 표현

분포의 퍼짐정도 측정

경험법칙

약 68%: $mean \pm 1\sigma$ 이내

약 95%: $mean \pm 2\sigma$ 이내

약 99.7%: $mean \pm 3\sigma$ 이내

종모양 분포에 적용

변동계수의 이해

상대적 산포도를 나타내는 척도
표준편차를 평균으로 나눈 값

$$CV = \frac{Error_{std}}{Mean} \times 100(\%)$$

필요성

평균크기가 다른 자료의 비교가능
표준편차는 절대적 척도의 한계존재
대표값의 크기를 감안한 분산도 측정
값이 작을수록 자료의 일관성이 높음

활용 사례

체중과 신장 비교: 단위가 다른변수의 비교
학생 공부시간 비교: 평균 3시간(cv = 16.7%) vs. 평균 6시간(cv = 13.3%)
투자위험성 평가: 수익률의 안정성 비교

첨도의 이해

분포가 중심에 얼마나 집중되어있는지의 정도
데이터분포의 뾰족한정도
분포의 일반적 특성이해에 도움

급첨분포

정규분포보다 더 뾰족
중심부근에 데이터 집중
꼬리부분이 두꺼움
이상치가 많이 발생할 가능성

완첨분포

정규분포보다 더 평평
데이터가 넓게분산
꼬리부분이 얇음
극단값 발생 가능성 낮음